scanspy Windows 命令行工具详细使用文档

本文档用于交付给 Windows 用户，说明如何运行 `scanspy.exe`，如何读取 JSON 返回值，以及每个枚举字段代表什么。本文档不会修改 release 目录里的 README。

单 EXE | 支持多个 PDF | 支持 PDF 直链 URL | Spring Boot 友好 JSON

快速说明

推荐先看

`scanspy.exe` 用于判断 PDF 是否需要 OCR。业务上主要读取 `scanned` 和 `type`：标准 PDF 返回 `STANDARD`，扫描 PDF 返回 `SCANNED`，部分页面需要 OCR 的 PDF 返回 `MIXED_SCANNED`。

输入

一个或多个本地 PDF 路径，或者一个或多个以 `.pdf` 结尾的 HTTP/HTTPS 直链。

输出

标准输出打印一行 JSON，外层固定为 `code/success/data/msg/errorCode`。

依赖

用户电脑不需要安装 Python、uv 或项目依赖，只运行 `scanspy.exe`。

命令格式

推荐在 PowerShell 中使用完整路径调用 exe，PDF 路径外层加英文双引号，避免中文、空格或括号导致命令解析错误。

```
C:\tools\scanspy\scanspy.exe "C:\Users\xxx\Desktop\a.pdf"
C:\tools\scanspy\scanspy.exe "C:\Users\xxx\Desktop\a.pdf" "C:\Users\xxx\Desktop\b.pdf"
C:\tools\scanspy\scanspy.exe "https://example.com/a.pdf"
```

URL 会先下载到系统临时目录中进行检测，检测完成后自动删除临时文件和临时目录。

JSON 结构

成功和失败时 `data` 内每个结果对象保持同一套字段，方便 Java 使用统一 DTO 反序列化。

字段	位置	说明
`code`	外层 / data item	HTTP 风格状态码。全部成功通常是 200；参数或 PDF 处理失败通常是 400。
`success`	外层 / data item	是否成功。多个 PDF 中有任意一个失败时，外层会体现失败或部分失败。
`data`	外层	数组，每个输入对应一个结果对象。
`source`	data item	原始输入，本地路径或 URL。
`fileName`	data item	文件名，例如 `a.pdf`。
`fileSize`	data item	文件大小，单位 byte。
`suffix`	data item	文件后缀，当前要求为 `PDF`。
`scanned`	data item	业务布尔值。`SCANNED` 和 `MIXED_SCANNED` 都返回 true；`STANDARD` 返回 false。
`type`	data item	文档类型枚举，见下面的 DocumentType。
`confidence`	data item	置信度字段。当前严格跟随 `ocr-detection` 公开 API，该库不提供置信度，所以统一为 0.0。
`pageCount`	data item	页数。当前库在 `SCANNED` 场景能返回页码列表；`STANDARD` 和 `MIXED_SCANNED` 不一定能给出完整页数。
`scannedPages`	data item	判定为需要 OCR 的页数或库返回的相关页码数量。
`textPages`	data item	当前严格公开 API 模式下不做额外手写页级检测，所以一般为 0。
`sourceType`	data item	输入来源枚举，见 SourceType。
`msg`	外层	中文提示信息。

字段	位置	说明
`errorCode`	外层	错误码。成功时为空字符串。

枚举说明

Java DTO 可对齐

下面把项目里的枚举逐个列出来，Java 侧可以按同名枚举建模。当前检测逻辑严格使用 `ocr-detection.detect_ocr()` 公开 API，不再叠加自定义 PDF 判断规则。

OCRStatus：ocr-detection 原始状态

库枚举值	原始值	项目映射结果	说明
`OCRStatus.FALSE`	`false`	`STANDARD`	不需要 OCR，项目按标准件处理，`scanned=false`。
`OCRStatus.TRUE`	`true`	`SCANNED`	需要 OCR，项目按扫描件处理，`scanned=true`。
`OCRStatus.PARTIAL`	`partial`	`MIXED_SCANNED`	部分页面需要 OCR，项目按混合扫描件处理，`scanned=true`。

DocumentType：文档类型

枚举值	中文含义	业务解释	scanned
`STANDARD`	标准件 / 文本型 PDF	`ocr-detection` 返回 `false`，通常表示不需要 OCR，可按普通 PDF 处理。	false
`SCANNED`	扫描件 / 纯图像 PDF	`ocr-detection` 返回 `true`，表示页面需要 OCR。项目会把它作为扫描件处理。	true
`MIXED_SCANNED`	混合扫描件	`ocr-detection` 返回 `partial`，表示只有部分页面需要 OCR，通常是文本页和扫描页混在一起。	true
`EMPTY`	空白 PDF	保留兼容字段。严格公开 API 模式不会主动返回该类型，因为 `ocr-detection` 不公开空白 PDF 的独立分类。	按库结果
`UNKNOWN`	未知类型	通常用于解析失败、参数错误、下载失败等异常结果。	false

PageType：页面类型

枚举值	中文含义	当前项目中的状态
`TEXT_PAGE`	文本页	保留给 Java 侧或未来扩展。当前严格公开 API 模式不返回单页明细。
`SCANNED_PAGE`	扫描页	保留给 Java 侧或未来扩展。当前只汇总 `scannedPages` 数量。
`UNKNOWN_PAGE`	未知页面	保留兼容，当前结果体不输出逐页页面类型。

SourceType：输入来源

枚举值	中文含义	说明
`FILE`	本地文件	输入是 Windows 本地 PDF 路径。
`URL`	PDF 直链	输入是 `http://` 或 `https://` 开头，并且路径后缀为 `.pdf` 的 URL。
`UNKNOWN`	未知来源	参数错误或无法识别输入类型时使用。

ErrorCode：错误码说明

错误码	中文含义	常见原因
`INVALID_ARGUMENT`	参数错误	没有传入参数，或者传入内容既不是 PDF 文件路径，也不是 PDF 直链 URL。
`PARTIAL_FAILURE`	部分失败	一次传入多个 PDF，其中至少一个处理失败。
`PDF_NOT_FOUND`	文件不存在	本地路径不存在。
`PDF_NOT_FILE`	不是文件	传入的是目录，或者不是普通文件。
`PDF_DOWNLOAD_ERROR`	下载失败	URL 网络不可达、超时、状态码异常或下载过程中断。
`PDF_URL_NOT_PDF`	URL 不是 PDF	URL 后缀不是 `.pdf`，或者响应内容不是 PDF 文件头。
`PDF_PARSE_ERROR`	PDF 解析失败	PDF 文件损坏、加密不可读，或者底层库无法解析。
`PDF_EMPTY`	PDF 没有页面	保留错误码，表示 PDF 没有可检测页面。

截图步骤

操作示例

下面是用户实际操作时可以照着执行的步骤。截图来自本机直接运行 `scanspy.exe` 的结果。

1 拿到交付文件

如果老板或实施人员给用户的是 zip，先解压。真正运行的是 `scanspy.exe`。

第 1 步：拿到交付文件

交付目录里至少有两个文件：

C:\Users\zhongerbing\Documents\xm\scanspy\release\scanspy-windows-x64\scanspy.exe
C:\Users\zhongerbing\Desktop\scanspy-用户使用文档\README-用户使用.txt

如果拿到的是 zip，先解压，再使用里面的 scanspy.exe。

2 打开命令行

推荐使用 PowerShell。用户不需要安装 Python、uv 或项目依赖。

第 2 步：打开命令行

在 Windows 开始菜单搜索 PowerShell 或 命令提示符。用户不需要安装 Python、uv 或任何依赖。运行时直接写 scanspy.exe 的完整路径，再跟 PDF 文件路径或 PDF 直链 URL。

3 检测本地标准 PDF

标准件返回 `STANDARD`，`scanned=false`。

本地标准件检测

```
PS C:\> "C:\Users\zhongerbing\Documents\xm\scanspy\release\scanspy-windows-x64\scanspy.exe" "C:\Users\zhongerbing\Desktop
\scanspy-标准件样本.pdf"
{
  "code": 200,
  "success": true,
  "data": [
    {
      "code": 200,
      "success": true,
      "source": "C:\\Users\\zhongerbing\\Desktop\\scanspy-标准件样本.pdf",
      "fileName": "scanspy-标准件样本.pdf",
      "fileSize": 2850,
      "suffix": "PDF",
      "scanned": false,
      "type": "STANDARD",
      "confidence": 0.0,
      "pageCount": 0,
      "scannedPages": 0,
      "textPages": 0,
      "sourceType": "FILE"
    }
  ],
  "msg": "操作成功",
  "errorCode": ""
}
```

看到 type=STANDARD、scanned=false，说明这是标准文本 PDF，不需要 OCR。

4 检测本地扫描 PDF

扫描件返回 `SCANNED`，`scanned=true`。

本地扫描件检测

```
PS C:\> "C:\Users\zhongerbing\Documents\xm\scanspy\release\scanspy-windows-x64\scanspy.exe" "C:\Users\zhongerbing\Desktop
\PDF合并.pdf"
{
  "code": 200,
  "success": true,
  "data": [
    {
      "code": 200,
      "success": true,
      "source": "C:\\Users\\zhongerbing\\Desktop\\PDF合并.pdf",
      "fileName": "PDF合并.pdf",
      "fileSize": 1490335,
      "suffix": "PDF",
      "scanned": true,
      "type": "SCANNED",
      "confidence": 0.0,
      "pageCount": 18,
      "scannedPages": 18,
      "textPages": 0,
      "sourceType": "FILE"
    }
  ],
  "msg": "操作成功",
  "errorCode": ""
}
```

看到 type=SCANNED、scanned=true，说明全部页需要 OCR。

5 检测混合 PDF

混合件返回 `MIXED_SCANNED`，`scanned=true`。

本地混合件检测

```
PS C:\> "C:\Users\zhongerbing\Documents\xm\scanspy\release\scanspy-windows-x64\scanspy.exe" "C:\Users\zhongerbing\Desktop
\附图1A发电机特性曲线-容量曲线.pdf"
{
  "code": 200,
  "success": true,
  "data": [
    {
      "code": 200,
      "success": true,
      "source": "C:\\Users\\zhongerbing\\Desktop\\附图1A发电机特性曲线-容量曲线.pdf",
      "fileName": "附图1A发电机特性曲线-容量曲线.pdf",
      "fileSize": 1725149,
      "suffix": "PDF",
      "scanned": true,
      "type": "MIXED_SCANNED",
      "confidence": 0.0,
      "pageCount": 0,
      "scannedPages": 19,
      "textPages": 0,
      "sourceType": "FILE"
    }
  ],
  "msg": "操作成功",
  "errorCode": ""
}
```

看到 type=MIXED_SCANNED，说明部分页需要 OCR。

6 一次检测多个 PDF

命令后面连续追加多个 PDF 路径即可，每个 PDF 在 `data` 数组中各有一个返回结果。

一次检测多个 PDF

```
PS C:\> "C:\Users\zhongerbing\Documents\xm\scanspy\release\scanspy-windows-x64\scanspy.exe" "C:\Users\zhongerbing\Desktop\scanspy-标准件样本.pdf" "C:\Users\zhongerbing\Desktop\PDF合并.pdf" "C:\Users\zhongerbing\Desktop\附图1A发电机特性曲线-容量曲线.pdf"
{
  "code": 200,
  "success": true,
  "data": [
    {
      "code": 200,
      "success": true,
      "source": "C:\\Users\\zhongerbing\\Desktop\\scanspy-标准件样本.pdf",
      "fileName": "scanspy-标准件样本.pdf",
      "fileSize": 2850,
      "suffix": "PDF",
      "scanned": false,
      "type": "STANDARD",
      "confidence": 0.0,
      "pageCount": 0,
      "scannedPages": 0,
      "textPages": 0,
      "sourceType": "FILE"
    },
    {
      "code": 200,
      "success": true,
      "source": "C:\\Users\\zhongerbing\\Desktop\\PDF合并.pdf",
      "fileName": "PDF合并.pdf",
      "fileSize": 1490335,
      "suffix": "PDF",
      "scanned": true,
      "type": "SCANNED",
      "confidence": 0.0,
      "pageCount": 18,
      "scannedPages": 18,
      "textPages": 0,
      "sourceType": "FILE"
    },
    {
      "code": 200,
      "success": true,
      "source": "C:\\Users\\zhongerbing\\Desktop\\附图1A发电机特性曲线-容量曲线.pdf",
      "fileName": "附图1A发电机特性曲线-容量曲线.pdf",
      "fileSize": 1725149,
      "suffix": "PDF",
      "scanned": true,
      "type": "MIXED_SCANNED",
      "confidence": 0.0,
      "pageCount": 0,
      "scannedPages": 19,
```

```
    "textPages": 0,
    "sourceType": "FILE"
   }
  ],
  "msg": "操作成功",
  "errorCode": ""
}
```


data 数组里每个输入对应一个结果，顺序与命令里的输入顺序一致。

7 检测 PDF 直链 URL

URL 必须是 HTTP/HTTPS，并且路径以 `.pdf` 结尾。

检测 HTTP/HTTPS PDF 直链


```
PS C:\> "C:\Users\zhongerbing\Documents\xm\scanspy\release\scanspy-windows-x64\scanspy.exe" "http://127.0.0.1:9649/scanspy-standard.pdf"
{
  "code": 200,
  "success": true,
  "data": [
   {
    "code": 200,
    "success": true,
    "source": "http://127.0.0.1:9649/scanspy-standard.pdf",
    "fileName": "scanspy-standard.pdf",
    "fileSize": 2850,
    "suffix": "PDF",
    "scanned": false,
    "type": "STANDARD",
    "confidence": 0.0,
    "pageCount": 0,
    "scannedPages": 0,
    "textPages": 0,
    "sourceType": "URL"
   }
  ],
  "msg": "操作成功",
  "errorCode": ""
}
```


截图使用本机临时 HTTP 地址演示。真实使用时换成以 .pdf 结尾的 PDF 直链。文件会下载到 %TMP% / %TEMP% 的 scanspy-* 临时目录，检测后自动删除。

8 常见错误：传入非 PDF

错误时仍然保持相同 JSON 结构，便于 Java 反序列化。

非 PDF 输入错误

```
PS C:\> "C:\Users\zhongerbing\Documents\xm\scanspy\release\scanspy-windows-x64\scanspy.exe" "C:\Users\zhongerbing\Desktop
\scanspy-用户使用文档\not-a-pdf.txt"
{
  "code": 400,
  "success": false,
  "data": [
    {
      "code": 400,
      "success": false,
      "source": "C:\\Users\\zhongerbing\\Desktop\\scanspy-用户使用文档\\not-a-pdf.txt",
      "fileName": "not-a-pdf.txt",
      "fileSize": 7,
      "suffix": "TXT",
      "scanned": false,
      "type": "UNKNOWN",
      "confidence": 0.0,
      "pageCount": 0,
      "scannedPages": 0,
      "textPages": 0,
      "sourceType": "UNKNOWN"
    }
  ],
  "msg": "输入必须是PDF文件或链接",
  "errorCode": "INVALID_ARGUMENT"
}
```

输入不是 .pdf 文件或 .pdf 直链时，外层 code=400，errorCode=INVALID_ARGUMENT。

9 JSON 字段说明

业务通常重点看 `scanned`、`type`、`source`、`fileName`、`errorCode`。

返回字段怎么看

code/success/msg/errorCode 是外层 R 结构。data 是数组，每个元素对应一个输入文件。type 可能是 STANDARD、SCANNED、MIXED_SCANNED 或 UNKNOWN。scanned 是给业务直接判断用的布尔值。source、fileName、fileSize、suffix 用于定位输入文件。

文档位置：C:\Users\zhongerbing\Desktop\scanspy-用户使用文档\scanspy-详细使用文档.html