scanspy 详细使用文档

Windows x64 命令行工具 | 更新日期 2026-09-10

本工具检测 PDF 的页面结构，并以 JSON 返回文档类型及业务判断标记。适用于本地文件、PDF 直链及批量调用；本工具不执行 OCR。

本次业务规则

混合扫描件 MIXED_SCANNED 的 scanned 已改为 false。只有纯扫描件 SCANNED 返回 true。type 和页数统计继续返回实际检测结果。

文档类型 type	scanned	含义
STANDARD	false	当前规则未识别到扫描页。
MIXED_SCANNED	false	存在扫描页，同时存在可提取文字。
SCANNED	true	存在扫描页，且文档中没有可提取文字。

运行要求和交付文件

面向 Windows 10 / Windows 11 的 64 位环境。用户无需安装 Python 或项目依赖。请在 PowerShell 或 CMD 中运行；直接双击不会显示文件选择窗口。

文件	用途
scanspy.exe	实际调用的单文件命令行程序。
README-用户使用.txt	快速运行与替换说明。
scanspy-详细使用文档.pdf	字段、分类、错误处理和调用示例。

快速开始

在 PowerShell 中运行以下命令，并将路径替换成实际位置：

```
& "C:\tools\scanspy\scanspy.exe" "C:\input\file.pdf"
```

判断文件类型前，先确认 code=200 且 success=true。scanned=false 本身不能代表处理成功。

运行方法

PowerShell

EXE 和 PDF 路径均建议使用英文双引号。以引号包裹 EXE 完整路径时，前面使用调用运算符 &。

```
& "C:\tools\scanspy\scanspy.exe" "C:\input\file.pdf"

& "C:\tools\scanspy\scanspy.exe" "https://example.com/file.pdf"

& "C:\tools\scanspy\scanspy.exe" "C:\input\a.pdf" "C:\input\b.pdf"
```

如果当前目录就是 EXE 所在目录，可直接使用：

```
.\scanspy.exe "C:\input\file.pdf"
```

CMD

CMD 中不使用 PowerShell 的 & 调用运算符：

```
"C:\tools\scanspy\scanspy.exe" "C:\input\file.pdf"
```

输入限制

1. 本地输入必须是 .pdf 文件路径，不接受 DOCX 或目录。文件名后缀不区分大小写。

2. 网络输入必须是 http:// 或 https:// 地址，URL 的路径部分以 .pdf 结尾，返回内容应为可读取的 PDF。网页预览地址不能直接使用。

3. 多个输入依次处理；data 数组与输入顺序对应，一个文件处理失败不会丢弃其他文件的结果。

网络文件与临时目录

PDF 直链会先下载到系统 %TMP% / %TEMP% 下的 scanspy-* 临时目录，再进行检测。正常结束或解析报错后会清理该临时目录。网络请求使用 20 秒超时设置；这不是整份 PDF 检测的总耗时上限。

输出和进程退出码

标准输出打印一行 UTF-8 编码的 JSON。所有输入处理成功时，进程退出码为 0；参数错误或任意输入处理失败时为 1。纯扫描件也可以处理成功并返回退出码 0，业务系统仍需读取 scanned。

JSON 字段说明

成功和失败结果的 data 均为数组。每个结果项的字段顺序和结构一致，方便按 R<List<ScanDetectResult>> 读取。以下 code 为 JSON 内的状态字段。

字段	位置	说明
code	外层及结果项	200 表示处理成功，400 表示处理失败。
success	外层及结果项	处理是否成功。批量调用需同时检查每个结果项。
data	外层	按输入顺序排列的结果数组。
source	结果项	原始输入路径或 URL。
fileName	结果项	文件名。
fileSize	结果项	文件大小，单位为字节。
suffix	结果项	文件后缀；成功的 PDF 输入为 PDF。
scanned	结果项	仅 SCANNED 为 true；STANDARD 和 MIXED_SCANNED 为 false。
type	结果项	文档类型；保留混合扫描件的细分信息。
confidence	结果项	固定为 0.0。当前结构规则不生成统计置信度。
pageCount	结果项	PDF 实际总页数。
scannedPages	结果项	当前结构规则识别为扫描页的数量。
textPages	结果项	存在可提取文字的页数，包含页眉页脚或页码文字。
sourceType	结果项	FILE、URL 或 UNKNOWN。
msg	外层	中文结果说明。失败详情读取此字段。
errorCode	外层	错误码；成功时为空字符串。

同一页可以同时计入 scannedPages 和 textPages，因此两项之和可能大于 pageCount。处理失败时页数通常为 0，不能作为成功检测的统计结果。

返回示例与分类解释

以下为两页混合 PDF 的完整返回格式示例。示例文件名、大小及页数仅用于说明字段，实际输出以输入文件为准。


```
{
  "code": 200,
  "success": true,
  "data": [
    {
      "code": 200,
      "success": true,
      "source": "C:\\input\\mixed.pdf",
      "fileName": "mixed.pdf",
      "fileSize": 12345,
      "suffix": "PDF",
      "scanned": false,
      "type": "MIXED_SCANNED",
      "confidence": 0.0,
      "pageCount": 2,
      "scannedPages": 1,
      "textPages": 1,
      "sourceType": "FILE"
    }
  ],
  "msg": "操作成功",
  "errorCode": ""
}
```


类型如何理解

STANDARD 表示当前规则未识别出扫描页，不保证文档中完全没有图片。空白页不影响文档类型，完全空白的 PDF 按 STANDARD 处理。

MIXED_SCANNED 表示存在扫描页且文档中存在可提取文字。文字页与扫描页混排、扫描页带 OCR 文字层，以及仅有可提取页眉页脚文字等情况，都可能归入混合扫描件；新版统一返回 scanned=false。

SCANNED 表示识别到扫描页且没有可提取文字，新版继续返回 scanned=true。EMPTY 为兼容保留类型，当前规则不主动返回；UNKNOWN 通常表示处理失败。

错误处理

请先检查处理状态，再应用 scanned 业务规则。失败结果也使用统一字段结构，type=UNKNOWN、scanned=false；这表示未完成有效判断，不能当作普通 PDF 放行。

errorCode	说明与处理建议
INVALID_ARGUMENT	未传参数、后缀不正确、URL 不符合要求等。核对命令与输入。
PARTIAL_FAILURE	批量输入中至少一个文件失败。逐项检查 data 中的 code 和 success。
PDF_NOT_FOUND	本地文件不存在。检查路径和文件名。
PDF_NOT_FILE	路径不是普通文件，例如传入了目录。
PDF_DOWNLOAD_ERROR	网络请求失败、超时或返回非成功状态。检查网络和 PDF 直链。
PDF_URL_NOT_PDF	URL 响应内容不是 PDF；URL 路径后缀错误通常属于 INVALID_ARGUMENT。
PDF_PARSE_ERROR	PDF 无法解析。检查文件是否损坏或不可读取。
PDF_EMPTY	兼容保留错误码；当前处理流程不主动抛出此错误。

批量调用

部分失败时，外层 code=400、success=false、errorCode=PARTIAL_FAILURE，但 data 仍保留所有输入的结果。成功文件的结果项 code=200；失败文件的结果项 code=400。失败详情位于外层 msg 和 errorCode。

接入顺序

1. 确认程序正常结束并且输出可以解析为 JSON。

2. 读取外层及各结果项的 code、success；对处理失败的文件按错误流程处理。

3. 对处理成功的结果读取 scanned。true 按纯扫描件处理；false 按本次业务约定处理，并保留 type 供详情展示。

替换与复核

替换旧版本

1. 确认业务系统实际调用的 scanspy.exe 完整路径，将本次交付的新 EXE 替换到该位置。保留现有命令行参数和 JSON 读取方式。

2. 若系统提示文件被占用，等待正在运行的检测进程结束后再替换。

3. 将本次 README 和 PDF 使用文档一并替换，避免继续参照旧版本中混合扫描件返回 true 的说明或旧截图。

用三类文件验证返回值

测试文件	预期 type	scanned
普通文字 PDF	STANDARD	false
文字与扫描页混合的 PDF	MIXED_SCANNED	false
无文字层的纯扫描 PDF	SCANNED	true

在 PowerShell 中可一次传入三份文件：

```
.\scanspy.exe "C:\input\standard.pdf" "C:\input\mixed.pdf" "C:\input\scanned.pdf"
```

如果已知混合扫描件仍返回 type=MIXED_SCANNED、scanned=true，请优先核对实际执行的 EXE 路径，确认旧版本已经替换。

统计和业务边界

scannedPages 是结构规则的命中数，不等于人工确认的扫描附件数量。textPages 统计任何可提取文字，不保证正文都有文字层。scanned=false 也不能直接说明文档无需 OCR。

本工具不判断营业执照、资质证书、合同等附件是否满足投标要求；附件内容的审核由业务系统承担。当前接口不返回逐页页码列表。

本次更新对应关系

混合扫描件的业务布尔值由 true 调整为 false；文档细分类型、实际总页数和页级计数继续保留。本版说明已更新页数统计口径，并移除了旧 OCR 接口映射和旧输出截图。